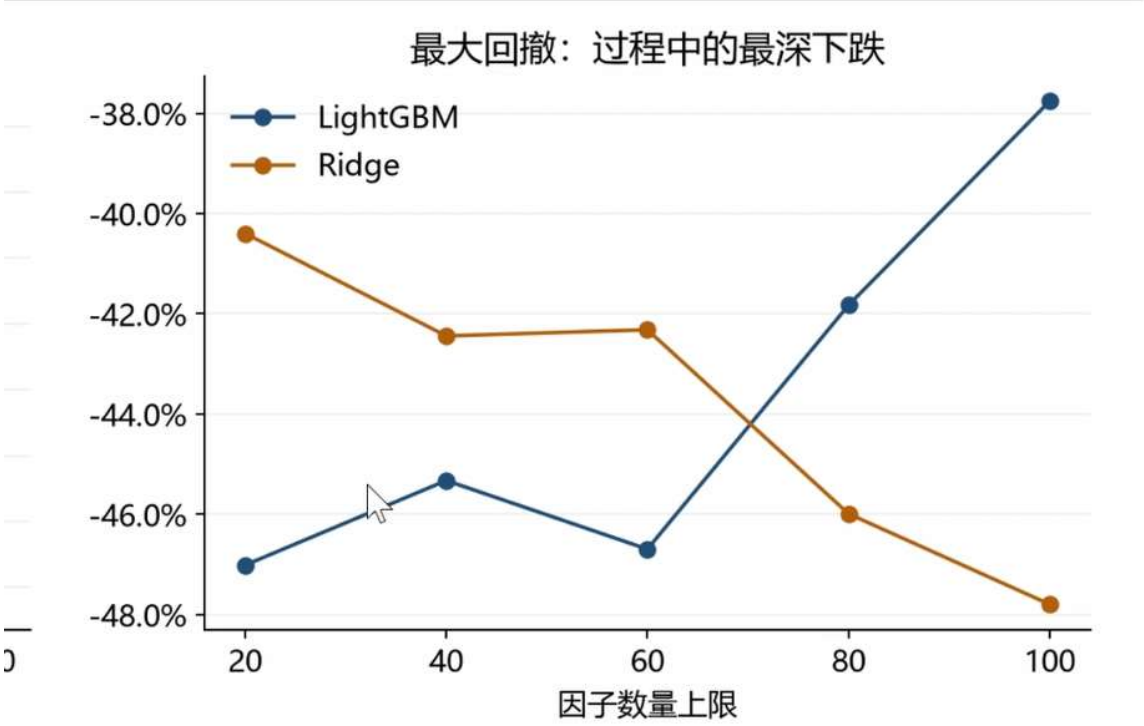
北交所历史选股有改善，但回撤仍然很大



读图：横轴：日期；纵轴：净值，1代表初始100万元。先比不同方法，再看中途下跌。

原40因子 +64.47%；价格基线 +14.40%；Ridge +88.24%；原40因子最大回撤 −45.33%。

问题：数据集怎么切分的？以2024/10为时点切分？前面train后面test? LightGBM对应的train/val/test各是哪一段？ num_leaves, learning_rate, n_estimators等参数如何确定的？Ridge具体怎么做的，正则部分权重如何取?共线性有无考虑？调仓频率为何?



问题：这个图，为什么两个算法趋势是反的？有没有直观的解释?

建议：

1）先把选因子选股做好，其它如分钟买入卖出、分红、HMM，暂时不考虑，手续费选万分之一，双边收取，滑点暂时不考虑。

1）先定一个持仓周期，如果每5日调仓，则计算 IC(5)，即因子s(t)和 r(t)=close(t+5+1)/open(t+1)之间的 rank IC，这个不能搞错。

3）价格数据使用后复权数据，天软因子都是后复权数据计算的。

4）重点去检查下回撤的原因，排除个别因素如价格错误；

5）如果回撤是大盘的问题，那么做一下因子市场和行业中性化，控制在不同风格、行业的股票的权重，应该可以较好的降低回撤。回撤是最重要的指标。回报率不高没关系，但回撤不能大，否则没有人敢用。

6）最后，数据回测和测试要滚动起来。严格按照如下逻辑：

要分 train/val/test 三个集合，但不是一次静态切分，而是**沿时间轴滚动的一组嵌套切分**。每个滚动时点 *t* 上：

```
窗口结构（h = 持仓天数）：

  [======== 训练 L_train ========][隔离带 h][== 验证 L_val ==][== 测试 H ==]
                                  ↑ 锚点 t                                ↑ 只评估一次，永不回头
```

具体流程：

1. **初始化**：设训练窗长 L_{train} （如 2–3 年日频数据）、验证窗长 L_{val} （如 3–6 个月）、测试步长 H （如 1 个月）。
2. **第 i 轮**：在 $[t_i - L_{train},\ t_i)$ 上训练 LightGBM，用验证窗 $[t_i + h,\ t_i + h + L_{val})$ 做早停和超参选择，然后在测试窗 $[t_i + h + L_{val},\ t_i + h + L_{val} + H)$ 上产生纯样本外预测——**该窗口只评估一次，之后永不再碰。**
3. **滚动**：锚点前移 H ，重复。每个测试窗的预测拼接起来，就是全样本的 OOS 预测序列，IC、分层、净费后回测全部只在这一段上算。
4. **窗口类型**：滚动窗（rolling，固定 L_{train} ）对新 regime 适应快；扩展窗（expanding，起点不动）数据更多更稳。日频数据噪声大、市场结构会变，一般用滚动窗，L_{train} 取 2–3 年量级。

三个必须遵守的细节：

- **隔离带（embargo）≥ h**：因为 label 是 h 日前向收益，训练区间最后 h 天的 label 会用到测试区间开头的行情。你之前定的 20 日隔离带纪律在这里就是 embargo 参数，持仓 20 天则隔离带至少 20 个交易日。这是 walk-forward 最容易犯的泄漏错误。
- **超参锁定规则**：每轮重训时，超参可以在当轮的 validation 上重新选（计算量大），也可以全流程只搜一次参然后固定——**不能**看测试窗表现回头改参，否则测试窗就退化成验证窗。
- **每轮重训是否必要**：H 步长小（如每周）则一年重训十几次，成本高；折中是 H 取 1 个月，或者只在模型性能监控显示衰减时触发重训（triggered refit）。
- 滚动轮次多时，"训练窗里做因子筛选"也要纳入每轮流程（point-in-time 地筛），不能用全样本筛完因子再回测，否则筛选本身泄漏未来信息。申万行业分类那个 point-in-time 表就是为这步准备的。
- 最终报告除 OOS IC/ICIR/分层收益外，一定要给**滚动轮次间的稳定性**（各测试窗 IC 的均值、标准差、最差轮次），这直接回答"模型是持续有效还是只在某段行情有效"——比单点 IC 数字更能揭示过拟合。