HMM 市场状态识别：简明实施手册

一、数据准备与特征工程

1.1 选择观测变量（Observation Features）

HMM 的输入是时间序列观测向量 $\mathbf{O}_t \in \mathbb{R}^D$。常用维度如下：

维度	典型特征	经济学含义
收益与波动	指数日收益率 r_t、实现波动率 $\sigma_t^{realized}$、VIX、VVIX	区分低波/高波状态
趋势强度	收益率自相关 $\rho(r_t, r_{t-h})$、ADX、价格动量 / 波动率比值	区分趋势/反转
流动性	Amihud 非流动性 $ILLIQ_t$、市场换手率、买卖价差	区分流动/非流动
横截面分散	因子收益截面标准差、行业收益分散度、个股相关性均值	识别风格混乱/事件
宏观与情绪	信用利差、期限利差、经济 Surprise 指数、融资余额变化	预判状态转换
尾部风险	收益率偏度、峰度、跳跃检测统计量 J_t、期权风险逆转	识别事件/危机状态

1.2 数据预处理 - 对波动率、Amihud 等右偏特征取对数：$\tilde{x}_t = \ln(x_t + \epsilon)$ - 对宏观因子做标准化或 YoY 变换，消除量纲 - 若 $D > 5$，建议先做 PCA 降维至 3–5 个主成分，避免协方差矩阵 Σ_k 估计不稳定

二、模型设定

2.1 确定隐状态数 K - 先验设定：$K = 2$（低波/高波）、$K = 3$（低波/高波/危机）、$K = 4$（低波趋势/低波反转/高波震荡/危机） - 用 BIC/AIC 在样本内辅助选择，但**不超过 4–5**，防止过拟合

2.2 选择发射分布（Emission Distribution） - 单变量：$P(O_t \mid S_t = k) = \mathcal{N}(\mu_k, \sigma_k^2)$ - 多变量：$P(\mathbf{O}_t \mid S_t = k) = \mathcal{N}(\boldsymbol{\mu}_k, \Sigma_k)$ - 若存在厚尾，可改用 t 分布或高斯混合发射

2.3 设定转移矩阵结构 - 无约束：所有状态可互转 - 约束型：限制"危机"只能转回"正常"，避免模型在极端状态下虚构不可能路径

三、滚动训练与参数估计

3.1 滚动窗口训练 - 设定回望窗口 W（如 $W = 252$ 日或 $W = 63$ 日） - 每 Δ 日（如 $\Delta = 21$ 日）用窗口内数据 $[\mathbf{O}_{t-W+1}, \ldots, \mathbf{O}_t]$ 重新估计参数 - 使用 Baum-Welch（EM 算法）最大化似然：

$$\hat{\theta} = \arg\max_{\theta} \ln P(\mathbf{O}_{1:W} \mid \theta)$$

其中 $\theta = \{\pi, A, \{\boldsymbol{\mu}_k, \Sigma_k\}_{k=1}^K\}$

3.2 避免前视偏差 - 严禁使用全样本平滑概率（Smoothed Probabilities）做交易 - 仅允许使用**滤波概率**（Filtered Probabilities）或**预测概率**

四、状态解码与标签固定

4.1 实时状态推断（前向滤波）

在时刻 t，基于历史观测 $\mathbf{O}_{1:t}$，计算当前处于各状态的概率：

$$\gamma_t(k) = P(S_t = k \mid \mathbf{O}_{1:t}) = \frac{\alpha_t(k)}{\sum_{j=1}^K \alpha_t(j)}$$

其中 $\alpha_t(k)$ 为前向变量，通过递推得到：

$$\alpha_t(k) = P(\mathbf{O}_t \mid S_t = k) \sum_{i=1}^K \alpha_{t-1}(i) A_{ik}$$

4.2 状态标签固定（Label Relabeling）

每次重新训练后，标签可能乱序。按经济逻辑强制排序：

- **按波动率排序**：以 $\mathrm{tr}(\Sigma_k)$ 从小到大重新编号
- **按收益排序**：以 μ_k（或 μ_k/σ_k）排序
- **复合规则**：先按波动率分层，再按收益排序

固定后得到具有稳定经济含义的状态：状态 0 = 低波动，状态 1 = 高波动，依此类推。

4.3 状态转移与持续期验证

- 计算期望持续期：$E[D_k] = \frac{1}{1-A_{kk}}$
- 与历史已知事件（股灾、疫情、熔断）对照，确认状态 3（危机）确实覆盖这些区间

五、应用于风险管理

5.1 动态风险预算

根据滤波概率调整组合目标波动率：

$$\sigma_{target,t} = \sum_{k=1}^{K} \gamma_t(k) \cdot \sigma_{target}^{(k)}$$

例如：$\sigma_{target}^{(crisis)} = 0.3 \times \sigma_{target}^{(normal)}$

5.2 波动率目标与杠杆管理

$$L_t = \frac{\sigma_{target}}{\sigma_{forecast,t}} \cdot \sum_{k} \gamma_t(k) \cdot L^{(k)}$$

其中 $L^{(k)}$ 为状态 k 下的杠杆上限。

5.3 尾部风险对冲触发

当危机状态概率超过阈值：$\gamma_t(\mathrm{crisis}) > \bar{\gamma}$（如 0.5），自动启动对冲头寸。

六、应用于因子择时

6.1 构建状态-因子条件收益矩阵

对每个因子 f，回测计算状态条件夏普：

$$Sharpe_{f,k} = \frac{\mathbb{E}[r_{f,t} \mid S_t = k]}{\sigma(r_{f,t} \mid S_t = k)}$$

6.2 概率加权因子配置

因子 f 在时刻 t 的权重由当前状态概率加权：

$$w_{f,t} = \sum_{k=1}^{K} \gamma_t(k) \cdot w_f^{(k)}$$

其中 $w_f^{(k)}$ 为状态 k 下因子 f 的最优权重（通过风险平价或均值-方差求解）。

6.3 状态转移预判调仓

利用一步预测概率提前调整：

$$P(S_{t+1} = j \mid \mathbf{O}_{1:t}) = \sum_{i=1}^{K} \gamma_t(i) \cdot A_{ij}$$

若预测高概率转入危机状态，提前 1–2 日降低动量因子暴露。

七、关键检查清单

步骤	核心原则
特征选择	覆盖波动、趋势、流动、宏观四维度，$D \leq 5$ 或 PCA 降维
训练方式	滚动窗口 + 定期重估，严禁前视
状态输出	只用滤波概率 $\gamma_t(k)$，不用平滑概率
标签固定	每次训练后按波动率/收益排序重新编号
交易应用	软切换优于硬切换，设置最小持仓期或概率确认阈值
过拟合防控	$K \leq 4$，窗口外验证状态-因子条件夏普的稳定性
